

Rapport J09 - Agrégations SQL et GROUP BY

Plan d'exécution SQL/Data - 16 semaines | S02 - J09

Base	sql_training
Table	raw.training_events
Durée prévue	90 min
État du timer	71 min consommées - 19 min restantes
Durée réelle définitive	À compléter à la clôture

1. Objectifs

Comprendre et utiliser COUNT, MIN, MAX, AVG et SUM ; distinguer COUNT(*), COUNT(colonne) et COUNT(NULL) ; produire des KPI globaux et regroupés ; maîtriser GROUP BY sur une ou plusieurs colonnes ; diagnostiquer une erreur de colonne non agrégée ; valider un script reproductible avec psql -f.

2. État initial du dataset

Le dataset contient 15 lignes. Résultats : total_rows = 15, min_event_id = 1, max_event_id = 18. Les identifiants non continus sont cohérents avec les travaux antérieurs sur les transactions et séquences.

3. COUNT(*) et COUNT(colonne)

COUNT(*) = 15 ; COUNT(event_value) = 15 ; COUNT(NULL) = 0. COUNT(*) compte toutes les lignes ; COUNT(colonne) ignore les NULL ; COUNT(NULL) retourne donc 0.

4. Agrégations globales

Résultats : total_events = 15 ; min_value = 1.00 ; max_value = 315.90 ; avg_value = 105.56 ; total_value = 1583.40. La moyenne globale mélange plusieurs types de mesures ; les regroupements donnent des KPI plus interprétables.

5. GROUP BY sur une dimension

Par source_system : 4 groupes (manual_psql 1, microgrid_poc 7, sensor_gateway 4, tomra_training 3). Par event_type : 6 groupes (temperature 4, machine_alarm 3, voltage 3, current 2, sensor_reading 2, training_test 1).

6. KPI regroupés

Les KPI par source_system retournent 4 lignes. Les KPI par event_type retournent 6 lignes. La moyenne de temperature est 28.00.

7. Challenge autonome

Prévision : 6 groupes. Résultat : 6 groupes. Challenge réussi. Un groupe correspond à une combinaison distincte (source_system, event_type).

8. Erreur volontaire, diagnostic et résolution

Erreur : column "training_events.event_value" must appear in the GROUP BY clause or be used in an aggregate function. event_value était sélectionnée sans appartenir au GROUP BY et sans agrégation. Règle : toute colonne sélectionnée doit être groupée ou agrégée.

9. Script reproductible

Fichier : documentation/semaine-02/jour-09/code/J09_aggregations_groupby.sql. Exécution via psql -f réussie sans erreur visible. Validation finale : 15 lignes, min_event_id = 1, max_event_id = 18. Aucune donnée modifiée.

10. Captures d'écran

J09-02 à J09-09 documentent COUNT, agrégations globales, GROUP BY, KPI regroupés, challenge autonome, erreur volontaire, correction et validation du script.

11. KPI de progression

Agrégations globales : validées ; COUNT(NULL) : compris ; GROUP BY source_system : 4 groupes ; GROUP BY event_type : 6 groupes ; GROUP BY multi-colonnes : 6 groupes ; prévision du challenge exacte ; erreur diagnostiquée et corrigée ; script psql -f validé ; modification involontaire : 0. Durée prévue : 90 min. À T+71 min : 19 min restantes. Durée réelle finale : à compléter.

12. Conclusion

J09 marque le passage de la lecture et du filtrage vers l'analyse agrégée. Les fonctions d'agrégation transforment les lignes détaillées en indicateurs synthétiques et GROUP BY permet de les calculer par dimensions métier.

13. Prochaines étapes

Poursuivre les agrégations et KPI de S02 ; introduire HAVING ; finaliser staging, commit et push de J09.

14. Potentiel de réutilisation pédagogique

Tutoriel de 8 à 12 min sur COUNT et GROUP BY ; module de 30 à 45 min avec démonstration, challenge et correction d'erreur ; actif portfolio composé du script SQL, des captures et du rapport.